


FIAP GRADUAÇÃO

BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO



MODELAGEM LINEAR PARA APRENDIZADO DE MÁQUINA

Professor Me. Eng. Rodolfo Magliari de Paiva

Computação Estatística com Python



Este é o ponto de convergência onde a **Estatística** se transforma em soluções práticas, impulsionadas pela **Linguagem de Programação Python**, criando assim um arsenal robusto para abordar desafios complexos e extrair insights valiosos a partir dos dados.

Após a **coleta, validação e limpeza dos dados**, obtemos um **conjunto de dados** pronto para a etapa de **análise estatística**.





Vale destacar:

- **Banco de Dados / Base de Dados:** Sistema que armazena e organiza dados de forma estruturada para consulta e uso.
- **Tabela:** Estrutura dentro do banco e dados, organizada em linhas e colunas.
- **Dataset:** Conjunto de dados utilizado para análise (pode vir de um banco ou arquivo).
- **DataFrame:** Estrutura em memória, semelhante a uma tabela, usada em programação para análise de dados.





KINDS OF DATA



A análise de dados depende diretamente do **tipo de variável**, pois cada tipo exige **técnicas diferentes**.

Variáveis Qualitativas e Quantitativas

As **variáveis** são características ou propriedades de uma população.

Essas variáveis são classificadas em dois grupos:

- Variáveis Qualitativas
- Variáveis Quantitativas



Qualitativas: São atributos, podendo ser classificadas em:

- Ordinal = Apresenta hierarquia.
Exemplos: Cargo, escolaridade, ...
- Nominal = Não apresenta hierarquia.
Exemplos: Cor, sexo, ...



Quantitativas: São números, podendo ser classificadas em:

- Discreta = Números de contagem.

Exemplos: nº de filhos, nº de peças, ...

- Contínua = Números mensuráveis.

Exemplos: Altura, peso, ...



Exercício 1:

Classifique as variáveis em qualitativa (nominal ou ordinal), ou quantitativa (discreta ou contínua):

- a) Quantidade de vendas anuais de uma determinada loja.
- b) Tamanho de refrigerantes (pequeno, médio e grande).
- c) Cargo dos funcionários de uma empresa.
- d) Rendimento financeiro.
- e) Formas de pagamento numa loja.

Resposta:

- a) Variável Quantitativa Discreta.
- b) Variável Qualitativa Ordinal.
- c) Variável Qualitativa Ordinal.
- d) Variável Quantitativa Contínua.
- e) Variável Qualitativa Nominal.



Exercício 2:

Encontre e classifique as variáveis em qualitativa (nominal ou ordinal), ou quantitativa (discreta ou contínua) na imagem ao lado.

Organização de Dados

As tabelas são uma maneira eficaz de resumir e organizar dados:

Idade (anos)	Nº de pessoas
12	5
18	22
27	25
32	16
40	3
65	1
	Total: 72

Atividades	Nº de alunos
visitas a museus	400
visitas a outras cidades	200
palestras	250
exposições	100
outras	50

As Tabelas de Distribuição de Frequências permitem identificar **insights** que **não são facilmente percebidos** em tabelas usuais.

Tabela de Distribuição de Frequências para Variáveis Qualitativas e Quantitativas no Python

Na Tabela de Distribuição de Frequências devemos ter as seguintes informações:

- **Variável (x_i):** Representa a característica de interesse, com os respectivos valores (dados).
- **Frequência Absoluta (f_i):** Representa a frequência que cada elemento se repetiu da variável.
- **Frequência Absoluta Acumulada (f_{ia}):** Representa a soma acumulativa da frequência absoluta.
- **Frequência Relativa (f_r):** Representa a porcentagem de ocorrência da frequência absoluta, também vista como chance.
- **Frequência Relativa Acumulada (f_{ra}):** Representa a soma acumulativa da frequência relativa, também vista como chance.

A montagem da primeira coluna da tabela difere em função do tipo de Variável Quantitativa.

Vejamos um exemplo para a construção desta tabela para **Variáveis Quantitativas Discretas**:

Exemplo:

No condomínio Enseada moram jovens, sendo:

06 jovens com 14 anos;

12 jovens com 15 anos;

09 jovens com 16 anos;

03 jovens com 17 anos.

Monte uma tabela de distribuição de frequências para representar os dados coletados.

Resposta:

Preparando o ambiente:

```
from collections import Counter
```

```
import pandas as pd
```

```
pd.set_option('display.max_rows', None)
```

```
pd.set_option('display.max_columns', None)
```

```
pd.set_option('display.width', None)
```


Criando a base de dados:

```
dados = [14]*6 + [15]*12 + [16]*9 + [17]*3
```

Frequência Absoluta (fi):

```
fi = pd.Series(Counter(dados)).sort_index()
```

Frequência Absoluta Acumulada (fia):

```
fia = fi.cumsum()
```

Frequência Relativa (fr):

```
fr = 100 * fi / fi.sum()
```

Frequência Relativa Acumulada (fra):

```
fra = fr.cumsum()
```

Montando a tabela:

```
tabela = pd.DataFrame({  
    'Frequencia_Absoluta': fi,  
    'Frequencia_Absoluta_Acumulada': fia,  
    'Frequencia_Relativa': fr,  
    'Frequencia_Relativa_Acumulada': fra  
})
```

Nome "Total" na última linha:

```
total_row = pd.Series({  
    'Frequencia_Absoluta': fi.sum(),  
    'Frequencia_Absoluta_Acumulada': '',  
    'Frequencia_Relativa': fr.sum(),  
    'Frequencia_Relativa_Acumulada': ''  
}, name='Total')
```

Tabela de Distribuição de Frequências:

```
tabela = pd.concat([tabela, total_row.to_frame().T])  
print(tabela)
```

Idade dos adolescentes do condomínio Enseada

Idade (x_i)	Frequência absoluta (f_i)	Frequência absoluta acumulada (f_{ia})	Frequência relativa (f_r)	Frequência relativa acumulada (f_{ra}) (%)
14	6	6	$\frac{6}{30}$ ou 20%	20
15	12	18	$\frac{12}{30}$ ou 40%	60
16	9	27	$\frac{9}{30}$ ou 30%	90
17	3	30	$\frac{3}{30}$ ou 10%	100
	$n = 30$		Total = 1 ou 100%	

Exercício 1:

Uma loja de roupas decidiu registrar o número de solicitações para a troca de peças compradas ao longo de 40 dias. Os resultados foram os da tabela a seguir:

14	15	15	16	14	13	16	17	14	16
15	17	17	15	16	15	14	14	13	15
16	14	15	14	16	14	14	15	16	14
13	14	15	17	16	15	16	14	15	17

Monte uma tabela de distribuição de frequências dos dados coletados.

Resposta:

Preparando o ambiente:

```
from collections import Counter
```

```
import pandas as pd
```

```
pd.set_option('display.max_rows', None)
```

```
pd.set_option('display.max_columns', None)
```

```
pd.set_option('display.width', None)
```

Criando a base de dados:

```
dados1 = [13]*3 + [14]*12 + [15]*11 + [16]*9 + [17]*5
```

Frequência Absoluta (fi):

```
fi = pd.Series(Counter(dados1)).sort_index()
```

Frequência Absoluta Acumulada (fia):

```
fia = fi.cumsum()
```

Frequência Relativa (fr):

```
fr = 100 * fi / fi.sum()
```

Frequência Relativa Acumulada (fra):

```
fra = fr.cumsum()
```

Montando a tabela:

```
tabela = pd.DataFrame({  
    'Frequencia_Absoluta': fi,  
    'Frequencia_Absoluta_Acumulada': fia,  
    'Frequencia_Relativa (%)': fr,  
    'Frequencia_Relativa_Acumulada (%)': fra  
})
```

Nome "Total" na última linha:

```
total_row = pd.Series({  
    'Frequencia_Absoluta': fi.sum(),  
    'Frequencia_Absoluta_Acumulada': pd.NA,  
    'Frequencia_Relativa (%)': fr.sum(),  
    'Frequencia_Relativa_Acumulada (%)': pd.NA  
}, name='Total')
```

Tabela de Distribuição de Frequências:

```
tabela = pd.concat([tabela, total_row.to_frame().T])  
print(tabela)
```


Variável	Frequência Absoluta	Frequência Absoluta Acumulada	Frequência Relativa (%)	Frequência Relativa Acumulada (%)
13	3	3	7,5	7,5
14	12	15	30	37,5
15	11	26	27,5	65
16	9	35	22,5	87,5
17	5	40	12,5	100
Total:	40		100	

Exercício 2:

Uma empresa de telefonia solicitou a um analista que coletasse o número de reclamações ao longo de 20 dias e os resultados foram:

1	5	6	5	2	2	2	4	6	5
2	3	3	1	6	6	5	5	4	2

Monte uma tabela com a distribuição das frequências dos dados.

Resposta:

Preparando o ambiente:

```
from collections import Counter
```

```
import pandas as pd
```

```
pd.set_option('display.max_rows', None)
```

```
pd.set_option('display.max_columns', None)
```

```
pd.set_option('display.width', None)
```

Criando a base de dados:

```
dados2 = [1]*2 + [2]*5 + [3]*2 + [4]*2 + [5]*5 + [6]*4
```

Frequência Absoluta (fi):

```
fi = pd.Series(Counter(dados2)).sort_index()
```

Frequência Absoluta Acumulada (fia):

```
fia = fi.cumsum()
```

Frequência Relativa (fr):

```
fr = 100 * fi / fi.sum()
```

Frequência Relativa Acumulada (fra):

```
fra = fr.cumsum()
```

Montando a tabela:

```
tabela = pd.DataFrame({  
    'Frequencia_Absoluta': fi,  
    'Frequencia_Absoluta_Acumulada': fia,  
    'Frequencia_Relativa (%)': fr.round(1),  
    'Frequencia_Relativa_Acumulada (%)': fra.round(1)  
})
```


Nome "Total" na última linha:

```
total_row = pd.Series({  
    'Frequencia_Absoluta': fi.sum(),  
    'Frequencia_Absoluta_Acumulada': pd.NA,  
    'Frequencia_Relativa (%)': fr.sum().round(1),  
    'Frequencia_Relativa_Acumulada (%)': pd.NA  
}, name='Total')
```

Tabela de Distribuição de Frequências:

```
tabela = pd.concat([tabela, total_row.to_frame().T])  
print(tabela)
```

x_i	f_i	f_{in}	f_r	f_{rn}
1	2	2	$\frac{2}{20} = 10\%$	10%
2	5	$2 + 5 = 7$	$\frac{5}{20} = 25\%$	35%
3	2	$7 + 2 = 9$	$\frac{2}{20} = 10\%$	45%
4	2	$9 + 2 = 11$	$\frac{2}{20} = 10\%$	55%
5	5	$11 + 5 = 16$	$\frac{5}{20} = 25\%$	80%
6	4	$16 + 4 = 20$	$\frac{4}{20} = 20\%$	100%
Total	20		100%	

Vejamos um exemplo para a construção desta tabela para **Variáveis Quantitativas Contínuas**:

Exemplo:

Foram coletados os “pesos” de 30 caixas para serem transportadas em um avião, para verificar a capacidade delas.

Os dados em kg, foram:

48; 48,2 ; 48,7; 49,1; 49,5; 49,8; 50,2; 50,3; 50,4; 50,6; 50,9; 50,6; 50,8;
50,4; 50,6; 51,2; 51,3; 51,2; 51,9; 51,8; 51,6; 52,8; 52,6; 52,8; 53; 53;
53; 53; 53; 53

Monte uma tabela de distribuição de frequências para os dados.

Resposta:

1º Amplitude Total (R):

$$R = \text{Máx} - \text{Mín}$$

$$R = 53\text{kg} - 48\text{kg}$$

$$R = 5\text{kg}$$

2º **Escolher** o número de intervalos de classe, que deve ser ≥ 4 ou $> R$:

nº de classes = 6 (**escolhido**)

3º Amplitude do Intervalo (A_i):

$$A_i = R / \text{nº de classes}$$

$$A_i = 5 / 6$$

$$A_i = 0,83... \approx 1$$

4º Preparando o ambiente:

```
import pandas as pd
```

```
pd.set_option('display.max_rows', None)
```

```
pd.set_option('display.max_columns', None)
```

```
pd.set_option('display.width', None)
```


Criando a base de dados:

```
dados = [  
    48, 48.2, 48.7, 49.1, 49.5, 49.8, 50.2, 50.3, 50.4, 50.6, 50.9, 50.6,  
    50.8, 50.4, 50.6, 51.2, 51.3, 51.2, 51.9, 51.8, 51.6, 52.8, 52.6, 52.8,  
    53, 53, 53, 53, 53, 53  
]
```

Definir os intervalos:

```
bins = [48, 49, 50, 51, 52, 53, 54]  
classes = pd.cut(dados, bins=bins, right=False)
```

Frequência Absoluta (fi):

```
fi = classes.value_counts().sort_index()
```

Frequência Absoluta Acumulada (fia):

```
fia = fi.cumsum()
```

Frequência Relativa (fr):

```
fr = (100 * fi / fi.sum()).round(2)
```

Frequência Relativa Acumulada (fra):

```
fra = fr.cumsum()
```

Montando a tabela:

```
total = pd.Series({  
    'Frequencia_Absoluta': fi.sum(),  
    'Frequencia_Absoluta_Acumulada': pd.NA,  
    'Frequencia_Relativa': fr.sum().round(2),  
    'Frequencia_Relativa_Acumulada': pd.NA  
}, name='Total')
```

Nome "Total" na última linha:

```
tabela = pd.DataFrame({  
    'Frequencia_Absoluta': fi,  
    'Frequencia_Absoluta_Acumulada': fia,  
    'Frequencia_Relativa': fr,  
    'Frequencia_Relativa_Acumulada': fra  
})
```

Tabela de Distribuição de Frequências:

```
tabela = pd.concat([tabela, total.to_frame().T])  
print(tabela)
```

Variável	Frequência Absoluta	Frequência Absoluta Acumulada	Frequência Relativa (%)	Frequência Relativa Acumulada (%)
[48; 49[	3	3	10	10
[49; 50[	3	6	10	20
[50; 51[	9	15	30	50
[51; 52[	6	21	20	70
[52; 53[	3	24	10	80
[53; 54[	6	30	20	100
Total:	30		100	

Exercício 1:

Os “pesos” de 50 pessoas voluntárias foram registrados para uma pesquisa médica de obesidade e os resultados foram os seguintes:

72	81	57	64	87	94	74	69	77	73
71	96	55	58	88	92	47	60	68	80
77	76	59	57	83	81	90	68	65	74
91	97	86	82	73	64	69	81	88	94
77	72	81	91	49	75	52	50	63	70

Monte uma tabela com a distribuição das frequências dos dados.

Resposta:

1º Amplitude Total (R):

$$R = \text{Máx} - \text{Mín}$$

$$R = 97\text{kg} - 47\text{kg}$$

$$R = 50\text{kg}$$

2º **Escolher** o número de intervalos de classe, que deve ser ≥ 4 ou $> R$:

nº de classes: 6 (**escolhido**)

3º Amplitude do Intervalo (A_i):

$$A_i = R / \text{nº de classes}$$

$$A_i = 50 / 6$$

$$A_i = 8,33 \approx 10$$

4º Preparando o ambiente:

```
import pandas as pd
```

```
pd.set_option('display.max_rows', None)
```

```
pd.set_option('display.max_columns', None)
```

```
pd.set_option('display.width', None)
```

Criando a base de dados:

```
dados1 = [  
    72, 81, 57, 64, 87, 94, 74, 69, 77, 73, 71, 96, 55, 58, 88, 92, 47, 60, 68, 80,  
    77, 76, 59, 57, 83, 81, 90, 68, 65, 74, 91, 97, 86, 82, 73, 64, 69, 81, 88, 94,  
    77, 72, 81, 91, 49, 75, 52, 50, 63, 70  
]
```

Definir os intervalos:

```
bins = list(range(40, 101, 10)) # [40,50,60,70,80,90,100]  
classes = pd.cut(dados1, bins=bins, right=False)
```

Frequência Absoluta (fi):

```
fi = classes.value_counts().sort_index()
```

Frequência Absoluta Acumulada (fia):

```
fia = fi.cumsum()
```

Frequência Relativa (fr):

```
fr = (100 * fi / fi.sum()).round(2)
```

Frequência Relativa Acumulada (fra):

```
fra = fr.cumsum()
```

Montando a tabela:

```
total = pd.Series({  
    'Frequencia_Absoluta': fi.sum(),  
    'Frequencia_Absoluta_Acumulada': pd.NA,  
    'Frequencia_Relativa': fr.sum().round(2),  
    'Frequencia_Relativa_Acumulada': pd.NA  
}, name='Total')
```

Nome "Total" na última linha:

```
tabela = pd.DataFrame({  
    'Frequencia_Absoluta': fi,  
    'Frequencia_Absoluta_Acumulada': fia,  
    'Frequencia_Relativa': fr,  
    'Frequencia_Relativa_Acumulada': fra  
})
```

Tabela de Distribuição de frequências:

```
tabela = pd.concat([tabela, total.to_frame().T])  
print(tabela)
```

Classe	f_i	f_{ia}	f_r	f_{ra}
[40; 50[	2	2	4%	4%
[50; 60[	7	9	14%	18%
[60; 70[	9	18	18%	36%
[70; 80[	13	31	26%	62%
[80; 90[	11	42	22%	84%
[90; 100[	8	50	16%	100%
Total	50		100%	

Para uma **Variável Qualitativa**, é mais comum apresentarmos apenas as colunas de Frequência Absoluta e Frequência Relativa. Veja o exemplo a seguir:

Esporte	fi	fr (%)
Futebol	2	16,67
Volei	3	25,00
Basquete	7	58,33
Total	12	100,00

Material Complementar

Para aprofundar o tema, consulte os seguintes materiais:

https://docs.ufpr.br/~prbg/public_html/ce003/freq.pdf

(Acesso em 08/2025).

<https://aws.amazon.com/pt/what-is/data-visualization/>

(Acesso em 08/2025).

https://www.ufrgs.br/probabilidade-estatistica/slides/slides_1/1-2_Descritiva_distribuicoes%20de%20freq.pdf (Acesso em 08/2025).

OBRIGADO!

Contato:
profrodolfo.paiva@fiap.com.br

Copyright © **2023** Professor Me. Eng. Rodolfo Magliari de Paiva

Todos direitos reservados. Reprodução ou divulgação total ou parcial deste documento é expressamente proibido sem o consentimento formal, por escrito, do Professor (autor).