


FIAP GRADUAÇÃO

BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO



MODELAGEM LINEAR PARA APRENDIZADO DE MÁQUINA

Professor Me. Eng. Rodolfo Magliari de Paiva

Análise Bivariada



O objetivo da **Análise Bivariada** é entender a relação entre **duas variáveis**. Ela se concentra na exploração e na compreensão da associação, dependência ou interação entre duas variáveis diferentes (simultaneamente).

Para isso, é necessário entender primeiro o conceito de associação entre duas variáveis.

A **análise da associação entre duas variáveis** busca compreender como elas **variam juntas**, identificando possíveis **influências ou dependências entre si**.

Cada conjunto de variáveis é observado em uma mesma **unidade observacional** (entidade ou objeto de onde se coletam os dados, como uma pessoa, animal, planta ou outro elemento estudado).

Exemplo:

Estudante 1: Estudou 2h, obteve uma nota 7,5.


Estudante 2: Estudou 5h, obteve uma nota 9,0.

OBS: Cada estudante individual é uma unidade observacional.

A associação entre duas variáveis pode ser do tipo:


- **Unilateral:** y depende de x ou x depende de y.

Exemplo: O preço da venda de um produto (y) depende do local de venda (x).




- **Bilateral:** y depende de x e x depende de y.

Exemplo: O peso (x) e a circunferência abdominal (y) de uma pessoa.



- **Indireta (ou Espúria):** w está relacionado com x, e w está relacionado com y, mas não implica que x e y estão relacionados.
Exemplo: Venda de sorvete na praia (x), casos de afogamento (y) e temperatura (w).





DATA MINING

Identificar essas relações pode ser desafiador, especialmente quando **nem todas as variáveis relevantes são conhecidas.**

Na IA, o **Aprendizado por Regras de Associação**, por meio da **mineração de dados**, busca descobrir relações significativas entre variáveis em grandes bases de dados (Big Data).

Exemplo Clássico: Caso Walmart



Haveria alguma relação entre venda de cerveja e fralda de bebê?

**exame.**[Home](#) > [PME](#)


O que a revolução dos dados pode fazer por sua empresa?

Entenda como o big data - a extraordinária quantidade de informações coletadas por novas tecnologias - pode ser usado para tornar sua empresa muito mais competitiva

Leitura completa disponível em:

<https://exame.com/pme/a-revolucao-dos-dados/>

(Acesso em 03/2026).



A associação entre duas variáveis pode ser determinada por diferentes métodos, conforme a **natureza das variáveis envolvidas**.

A **classificação dessas variáveis define a técnica de análise estatística** mais adequada para investigar o tipo e a intensidade da relação existente entre elas.

- **Variável Qualitativa x Variável Qualitativa:**

Devemos usar as Tabelas de Contingência, o Teste Qui-Quadrado, o Gráfico de Mosaico e o Gráfico de Barras.

- **Variável Quantitativa x Variável Quantitativa:**

Devemos usar o Gráfico de Dispersão, a Covariância, a Correlação Linear de Pearson e o Gráfico de Correlação Linear de Pearson.

- **Variável Quantitativa x Variável Qualitativa:**

Devemos usar o Boxplot e o Teste para Comparação de Médias.


Em nossa disciplina, iremos estudar a associação entre duas variáveis quantitativas.

Gráfico de Dispersão

Também chamado de **Scatterplot**, a utilização deste gráfico é muito importante para descobrir se duas variáveis quantitativas estão associadas, analisando o comportamento da **nuvem de pontos**.

A **associação** entre duas variáveis quantitativas é chamada de **correlação**.

A seguir, veremos diferentes padrões que uma nuvem de pontos pode apresentar.






Figura 1: Correlação linear perfeita positiva.




Figura 2: Correlação linear perfeita negativa.




Figura 3: Não existe correlação.




Figura 4: Não existe relação linear.

Com isso, percebemos que o **Gráfico de Dispersão** é uma forma **subjetiva** de perceber a associação entre duas variáveis quantitativas.

Para determinar essa associação de forma **objetiva**, utilizamos a **Covariância** e a **Correlação Linear de Pearson**.

Covariância

A Covariância é uma medida descritiva da **associação linear** entre duas **variáveis quantitativas**, ou seja, ela mede a relação conjunta entre duas variáveis aleatórias.

Seu objetivo é descrever como duas variáveis tendem a variar juntas.

A relação matemática da Covariância é dada por:

Covariância
Populacional

$$\sigma_{XY} = \frac{\sum (X_i - \mu_X)(Y_i - \mu_Y)}{n}$$

Covariância
Amostral

$$s_{XY} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1}$$

Interpretação:

O resultado da Covariância pode ser:

- **Negativo**, significa que as variáveis têm relação linear oposta, enquanto uma aumenta, a outra diminui.
- **Positivo**, significa que as variáveis têm relação linear direta, enquanto uma aumenta, a outra também aumenta.
- **Nulo**, significa que não há relação linear entre as variáveis.

Porém, a Covariância não é uma medida estatística padronizada, ou seja, não possui uma escala padronizada.

De modo a deixar esta medida estatística padronizada, temos a **Correlação Linear de Pearson**.

Correlação Linear de Pearson

Também chamada de
**Coeficiente de Correlação
Linear de Pearson**, este nome
é dado em homenagem a
Karl Pearson, considerado o
Pai da Estatística.

Pearson foi um grande
matemático, estatístico,
historiador, filósofo, biógrafo e
psicólogo britânico.



Karl Pearson
1857 - 1936

A relação matemática da Correlação Linear de Pearson é dada por:

Correlação Linear de
Pearson Populacional

$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

Correlação Linear de
Pearson Amostral

$$r_{XY} = \frac{s_{XY}}{s_X s_Y}$$

As relações matemáticas anteriores podem ser reescritas da seguinte forma:

$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = \frac{\sum (X_i - \mu_X)(Y_i - \mu_Y)}{\sqrt{\sum (X_i - \mu_X)^2} \sqrt{\sum (Y_i - \mu_Y)^2}}$$

$$r_{XY} = \frac{s_{XY}}{s_X s_Y} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2} \sqrt{\sum (Y_i - \bar{Y})^2}}$$

Interpretação:

$$-1 \leq \rho \leq +1 \quad \text{ou} \quad -1 \leq r \leq +1$$


Onde:

ρ ou $r = +1$, correlação linear perfeita e positiva.

ρ ou $r = -1$, correlação linear perfeita e negativa.

ρ ou $r = 0$, não existe correlação linear.

Esquemáticamente tem-se para os resultados de ρ ou r :





Utilizamos a tabela abaixo como referência:

Valor de ρ (+ ou -)	Interpretação
0.00 a 0.19	Uma correlação bem fraca
0.20 a 0.39	Uma correlação fraca
0.40 a 0.69	Uma correlação moderada
0.70 a 0.89	Uma correlação forte
0.90 a 1.00	Uma correlação muito forte

Gráfico de Correlação Linear de Pearson

O Gráfico de Correlação Linear de Pearson mostra de forma visual a correlação linear entre as variáveis em estudo:






A partir dos resultados das análises anteriores, podemos entender **se é viável aplicar modelos de previsão ou classificação, e qual tipo de modelo** pode ser mais adequado.

Vale Destacar: É chamada de **Correlação Espúria** aquela onde existe associação entre as variáveis, porém **não há relação de causa e efeito entre elas.**

Exemplo:



Site: <https://tylervigen.com/spurious-correlations>

A **Correlação**, mesmo quando quantificada, **não explica o porquê nem o como de uma relação**, ela apenas mede o grau de associação entre variáveis.

Causalidade, por sua vez, refere-se à contribuição de um evento para a ocorrência de outro, de modo que a causa é parcialmente responsável pelo efeito, e o efeito é parcialmente dependente da causa.

Para estabelecer corretamente uma relação de causa e efeito, é necessário verificar:

- Associação significativa entre as variáveis (medida de correlação);
- Associação temporal, isto é, se a relação se repete ao longo do tempo;
- Ausência de fatores de confusão que possam levar a conclusões equivocadas.

Análise de Regressão




A **Análise de Regressão** é uma técnica estatística que estuda a relação entre duas ou mais variáveis, sendo elas dependentes e independentes, permitindo identificar quais variáveis têm maior ou menor impacto em um fenômeno de estudo.

Os Modelos de Regressão são utilizados para tarefas que envolvem **previsões** e **classificações** de dados.

O estudo da Correlação e da “Regressão”
teve origem com o inglês Francis Galton.

Ele foi matemático, explorador,
antropólogo, geneticista, psicólogo,
geógrafo, meteorologista, estatístico,
filósofo, sociólogo, escritor, fotógrafo,
inventor e fisiólogo.



Francis Galton
(1822 – 1911)



O estudo começou com a altura de pais e a altura de filhos.

A pergunta que Galton buscava responder era:

“Quanto maior a altura do pai, maior será a altura do filho?”

Foi quando ele descobriu o **Fenômeno de Regressão à Média**.

Quando aplicado para alturas, este fenômeno diz:

“Pais altos tendem a ter filhos mais altos,
pais mais baixos tendem a ter filhos mais baixos.
Porém, pais extremamente altos, tendem a ter filhos mais baixos do que eles.
E pais extremamente baixos tendem a ter filhos mais altos do que eles”.

Ou seja, estes dois últimos casos, a altura dos filhos **regridem para a média**.

An abstract graphic on the left side of the slide, featuring a complex network of glowing blue nodes and connecting lines, resembling a molecular structure or a data network, set against a dark blue background.

O conceito de **regressão** está relacionado à **normalização dos fenômenos**. O Fenômeno de Regressão à Média é um processo natural que ocorre em qualquer conjunto de eventos aleatórios, indicando que **resultados extremos tendem, por mero acaso, a ser seguidos por valores mais próximos da média.**

Em outras palavras, ocorrências excepcionais dificilmente se repetem, pois os extremos tendem a retornar a níveis intermediários, refletindo a tendência natural dos fenômenos à estabilidade e não à perpetuação de extremos.

No exemplo anterior, que relaciona a altura de pais e filhos, **se o Fenômeno de Regressão à Média não existisse**, pais extremamente altos tenderiam a ter filhos ainda mais altos, enquanto pais extremamente baixos teriam filhos ainda mais baixos.

Com o passar das gerações, isso levaria a uma população composta apenas por extremos, como indivíduos muito baixos e muito altos.




Com o passar do tempo, o nome **Fenômeno de Regressão à Média** passou a ser chamado de **Análise de Regressão** pelo inglês Ronald Fisher com o objetivo de predição.

Este, foi estatístico, biólogo evolutivo e geneticista.



Ronald Fisher
(1890 – 1962)



Conforme outros estudiosos foram surgindo, novos Modelos de Regressão foram descobertos, tendo aplicações nas mais diversas áreas do conhecimento.

Em **IA**, os algoritmos de **Regressão e Classificação** pertencem ao **Aprendizado de Máquina Supervisionado**.

Machine Learning

O que é e qual sua importância?

O aprendizado de máquina (em inglês, machine learning) é um método de **análise de dados** que automatiza a construção de modelos analíticos. É um ramo da **inteligência artificial** baseado na ideia de que sistemas podem aprender com dados, identificar padrões e tomar decisões com o mínimo de intervenção humana.

Leitura completa disponível em:


https://www.sas.com/pt_br/insights/analytics/machine-learning.html

(Acesso em 02/2023).




O foco desta disciplina é o Aprendizado de Máquina Supervisionado:


CLASSIFICAÇÃO



REGRESSÃO



Regressão Linear



A **Regressão Linear** é uma técnica para ser aplicada quando existe **Correlação Linear** entre as variáveis envolvidas.

A variável resposta (variável dependente), é obrigatoriamente **quantitativa contínua** (numérica).

Regressão Linear

Simples:

Possui apenas uma variável preditiva ou regressora (variável independente).

A equação do modelo de uma Regressão Linear Simples é dada por:

$$\hat{Y} = \hat{a} + \hat{\beta}X + \varepsilon$$

Onde:

$\hat{Y}$ = Estimativa da Variável Dependente ou Resposta

$\hat{a}$ = Estimativa do Coeficiente Linear ou Intercepto

$\hat{\beta}$ = Estimativa do Coeficiente Angular ou Inclinação

X = Variável Independente ou Preditiva ou Regressora ou Explicativa

ε = Erro, resultado de flutuações aleatórias

Aplicando o **Método OLS (Ordinary Least Squares)** ou **MQO (Mínimos Quadrados Ordinários)**, os coeficientes $\hat{\alpha}$ e $\hat{\beta}$ são obtidos:

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}$$


Esse método busca minimizar a soma dos quadrados dos resíduos (SQR).

O gráfico da Regressão Linear Simples é uma **reta** no **Plano Cartesiano**:

Vale lembrar:

Eixo y = Eixo das Ordenadas

Eixo x = Eixo das Abscissas



Após aplicar o modelo, é interessante analisar o **R^2 (Coeficiente de Determinação)**.

É um indicador que mede a qualidade do ajuste na Regressão Linear Simples, ou seja, quanto que a variável preditiva **X** explica **Y**.

O R^2 é dado por:

$$R^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

Seu resultado varia de 0 a 1, sendo que:

- Quanto mais próximo de 0, menos a Regressão Linear Simples se ajustou;
- Quanto mais próximo de 1, mais a Regressão Linear Simples se ajustou.

Após analisar o R^2 , devemos verificar o **R^2 ajustado**.

O R^2 ajustado é uma versão modificada do R^2 que leva em conta o número de variáveis independentes no modelo, penalizando a inclusão de variáveis que não melhoram significativamente o modelo.

Seu uso é mais adequado com a Regressão Linear Múltipla, pois corrige o R^2 para evitar a superestimação da qualidade do modelo causada pelo aumento do número de variáveis.

O R^2 ajustado é dado por:

$$R^2_{\text{ajustado}} = 1 - \left(\frac{(1 - R^2)(n - 1)}{n - p - 1} \right)$$

Onde:

n = Tamanho da amostra

p = Número de variáveis independentes

Seu resultado varia de 0 a 1, sendo que:

- Quanto mais próximo de 0, menos a Regressão Linear Simples se ajustou;
- Quanto mais próximo de 1, mais a Regressão Linear Simples se ajustou.

Também é interessante analisar o resultado do
Teste F de Fisher-Snedecor.

O resultado do Teste F é crucial para determinar a relevância estatística do modelo de regressão como um todo (qualidade), e pode ajudar a decidir se o modelo é adequado para explicar a relação entre as variáveis envolvidas.

Teste F de Fisher-Snedecor

Declaração das hipóteses:

$H_0: \beta = 0$ (Modelo não é significativo)

$H_1: \beta \neq 0$ (Modelo é significativo)


Decisão:

$p\text{-value} \leq 0,05$ ($\alpha = 5\%$) $\Rightarrow$ Rejeitamos H_0

$p\text{-value} > 0,05$ ($\alpha = 5\%$) $\Rightarrow$ Aceitamos H_0

Nível Descritivo

Nível de Significância



Exemplo:

Um biólogo pretende estudar a relação entre um determinado poluente despejado por uma fábrica em um riacho e o dano causado em curso d'água em um valor de dano qualquer. Para isso, ele monta a tabela ao lado com os dados que possui.

Quantidade Poluente ($\mu\text{g/L}$)	Dano Ecológico
1	3
2	6
3	7
4	10
5	10
6	12

Aplique a Regressão Linear Simples nos dados para prever a variável Dano Ecológico, em função da variável Quantidade Poluente contendo:

- a) Um estudo completo da associação entre as variáveis Quantidade Poluente e Dano Ecológico.
- b) A Reta de Regressão Linear Simples no Gráfico de Dispersão.
- c) A Equação da Regressão Linear Simples.
- d) Verificação da adequação do modelo (R^2 e Teste F).
- e) Se a quantidade de poluente for $9\mu\text{g/L}$, qual o dano ecológico esperado?

Resposta:

Primeiramente devemos baixar e habilitar as bibliotecas:

```
import pandas as pd
```

```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
import statsmodels.api as sm
```

Na sequência, montar o conjunto de dados:

```
dados = pd.DataFrame({  
    'Qtd_Poluyente': [1, 2, 3, 4, 5, 6],  
    'Dano_Eco': [3, 6, 7, 10, 10, 12]  
})
```

```
a) sns.scatterplot(x='Qtd_Poluyente', y='Dano_Eco', data=dados)
plt.title('Dispersão: Quantidade de Poluente x Dano Ecológico')
plt.xlabel('Quantidade de Poluentes (µg/L)')
plt.ylabel('Dano Ecológico')
plt.show()
```

```
print(np.cov(dados['Qtd_Poluyente'], dados['Dano_Eco'])[0, 1])
```

```
print(np.corrcoef(dados['Qtd_Poluyente'], dados['Dano_Eco'])[0, 1])
```

```
sns.heatmap(dados.corr(), annot=True, cmap='coolwarm')
```

```
plt.title("Mapa de Correlação")
```

```
plt.show()
```

```
b) X = sm.add_constant(dados['Qtd_Poluyente'])  
    modelo = sm.OLS(dados['Dano_Eco'], X).fit()
```

```
sns.regplot(x='Qtd_Poluyente', y='Dano_Eco', data=dados, ci=None,  
            line_kws={"color": "red"})
```

```
plt.title('Gráfico de Dispersão com Reta de Regressão')
```

```
plt.xlabel('Quantidade de Poluentes (µg/L)')
```

```
plt.ylabel('Dano Ecológico')
```

```
plt.show()
```

c) `print(modelo.summary())`

Montar a equação com base nos resultados.

d) `print(modelo.summary())`

e) `nova_obs = 9`

`intercepto, coeficiente = modelo.params`

`print(intercepto + coeficiente * nova_obs)`

Exercício 1:

Foram observados 4 lotes aleatórios de sucos, cada um com a sua respectiva quantidade (em mg) por pacote e o volume de água necessário (em ml). Os dados foram organizados na tabela ao lado:

Quantidade (mg)	Volume de Água (ml)
100	50
200	70
400	100
500	120

Aplique a Regressão Linear Simples nos dados para prever a variável Volume de Água, em função da variável Quantidade contendo:

- a) Um estudo completo da associação entre as variáveis Volume de Água e Quantidade.
- b) A Reta de Regressão Linear Simples no Gráfico de Dispersão.
- c) A Equação da Regressão Linear Simples.
- d) Verificação da adequação do modelo (R^2 e Teste F).
- e) Se a quantidade for de 320mg, qual o dano ecológico esperado?

Exercício 2:

Observe a tabela a seguir com dados de alguns ciclistas:

Ciclista	Quilômetros Percorridos (km)	Tempo Gasto (h)
1	10	0.5
2	15	0.7
3	8	0.4
4	20	1.0
5	25	1.2

Aplique a Regressão Linear Simples nos dados contendo:

- a) Um estudo completo da associação entre as variáveis.
- b) A Reta de Regressão Linear Simples no Gráfico de Dispersão.
- c) A Equação da Regressão Linear Simples.
- d) Verificação da adequação do modelo (R^2 e Teste F).
- e) Se um ciclista percorrer 32 km, qual o tempo gasto esperado?

Exercício 3:

Observe a tabela a seguir com dados de todos os participantes de uma pesquisa:

Pessoa	Horas de TV por Dia (h)	Horas de Atividade Física por Semana (h)
1	3	10
2	4	8
3	2	12
4	5	7
5	1	15

Aplique a Regressão Linear Simples nos dados contendo:

- a) Um estudo completo da associação entre as variáveis.
- b) A Reta de Regressão Linear Simples no Gráfico de Dispersão.
- c) A Equação da Regressão Linear Simples.
- d) Verificação da adequação do modelo (R^2 e Teste F).
- e) Se uma pessoa assistir TV por 7h, qual o tempo esperado para ela praticar atividade física?

Material Complementar

Para aprofundar o tema, consulte os seguintes materiais:

https://docs.ufpr.br/~vayego/pedeefes/resumo_05.pdf

(Acesso em 10/2025).

<https://docs.ufpr.br/~jomarc/regressao.pdf> (Acesso em 10/2025).

<http://www5.eesc.usp.br/saate/index.php/saate/Indicar-a-T%C3%A9cnica/Relacionar/2.-%C3%81rvore-de-Decis%C3%A3o/Gloss%C3%A1rio/An%C3%A1lise-de-Regress%C3%A3o> (Acesso em 10/2025).

OBRIGADO!

Contato:
profrodolfo.paiva@fiap.com.br

Copyright © **2023** Professor Me. Eng. Rodolfo Magliari de Paiva

Todos direitos reservados. Reprodução ou divulgação total ou parcial deste documento é expressamente proibido sem o consentimento formal, por escrito, do Professor (autor).