


FIAP GRADUAÇÃO


BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO



MODELAGEM LINEAR PARA APRENDIZADO DE MÁQUINA

Professor Me. Eng. Rodolfo Magliari de Paiva

Análise Univariada com a Estatística Descritiva no Python



A **Estatística Descritiva** é o ramo da Estatística responsável por **coletar, organizar, resumir e descrever os dados de um fenômeno**, permitindo **compreender seu comportamento por meio de tabelas, gráficos e medidas estatísticas**.

A partir dessas técnicas, realizamos a **Análise Exploratória de Dados (AED)**, que auxilia na **identificação de padrões, tendências e características importantes dos dados**.

No Python, para realizar uma Análise Exploratória de Dados por meio da Estatística Descritiva, **é necessário instalar bibliotecas.**

As funções permitem realizar a **Análise Exploratória de Dados (AED)** que deve conter:

- Tabelas de Distribuição de Frequências;
- Gráficos Estatísticos;
- Medidas de Tendência Central;
- Medidas de Dispersão;
- Medidas Separatrizes.



Medidas de Tendência Central (Posição): São medidas que mostram a convergência dos dados.

Sendo elas:

- Média;
- Mediana;
- Moda.

OBS:

Quanto **mais próximos** esses resultados, **mais homogêneo** é o conjunto de dados.

Quanto **mais distantes** esses resultados, **mais heterogêneo** é o conjunto de dados.

Média: Representa a esperança, também chamada de ponto de equilíbrio.

$$\bar{X} = \frac{\sum x_i}{n}$$

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])  
print(x.mean())
```

Mediana: Representa o elemento central de um conjunto de dados em rol (ordenados de forma crescente ou decrescente).

$$Md = \begin{cases} X_{(\frac{n+1}{2})}, & \text{se "n" é ímpar} \\ \frac{X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}}{2}, & \text{se "n" é par} \end{cases}$$

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])  
print(x.median())
```

Moda: Representa o(s) elemento(s) com maior Frequência Absoluta (fi), podendo ser:

Mo: Amodal = Nenhuma moda

Mo: Unimodal = 01 Moda

Mo: Bimodal = 02 Modas

Mo: Multimodal $\geq$ 03 Modas

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])
```

```
tabela = x.value_counts().sort_index()
```

```
print(tabela) (Deste é modo é necessário informar a(s) Moda(s) usando #)
```

Outro modo de encontrar a Moda em um conjunto de dados é:

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])  
print(x.mode())
```

Medidas de Dispersão: São medidas que mostram a variabilidade dos dados.

Sendo elas:

- Máximo;
- Mínimo;
- Amplitude;
- Variância Amostral;
- Desvio Padrão Amostral;
- Coeficiente de Variação Amostral.

Máximo: Representa o maior valor do conjunto de dados (X_n).

Mínimo: Representa o menor valor do conjunto de dados (X_1).

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])
```

```
print(x.max())
```

```
print(x.min())
```

ou

```
print([x.min(), x.max()])
```

Amplitude: Representa a distância entre o valor máximo e o valor mínimo em um conjunto de dados.

$$R = X_{(n)} - X_{(1)}$$

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])
```

```
R = x.max() - x.min()
```

```
print(R)
```

Variância Amostral: Representa a variabilidade ao redor da média, porém, esta medida altera a grandeza dos dados.

$$s^2 = \frac{\sum (x_i - \bar{X})^2}{n - 1}$$

→ A potência é utilizada para evitar que os desvios em relação à média se anulem quando somados. Chamamos de Discrepância o resultado sem a potência e a divisão.

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])  
print(x.var())
```

Desvio Padrão Amostral: Representa a variabilidade ao redor da média, desta vez, na grandeza correta dos dados.

$$s = \sqrt{s^2}$$

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])  
print(x.std())
```

Coeficiente de Variação Amostral: Representa uma medida relativa entre o Desvio Padrão Amostral e a Média, dada em %.

$$CV = \frac{s}{\bar{x}} \cdot 100$$

Exemplo:

```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])
```

```
CV = (x.std() / x.mean()) * 100
```

```
print(CV)
```

Outro modo de encontrar o Coeficiente de Variação em um conjunto de dados é por meio da criação de uma função.

```
import pandas as pd
```

```
def CV(x):  
    return (x.std() / x.mean()) * 100
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])  
print(CV(x))
```

A **classificação** da variabilidade dos dados é dada em função do **resultado do Coeficiente de Variação**:


Baixo	$CV < 10\%$
Médio	$10\% \leq CV < 20\%$
Alto	$20\% \leq CV < 30\%$
Muito Alto	$CV \geq 30\%$

Medidas Separatrizes: São medidas que separam o conjunto de dados em partes iguais; podendo ser:

- Quartil;
- Decil;
- Centil.

OBS: Para o cálculo de todas as medidas separatrizes, os dados sempre devem ser colocados em **rol** (ordem crescente ou decrescente).

Quartil: São os valores que dividem um conjunto de dados em 4 partes iguais.



Onde:

Q_1 = 25% dos dados abaixo e 75% dos dados acima

Q_2 = 50% dos dados abaixo e 50% dos dados acima

Q_3 = 75% dos dados abaixo e 25% dos dados acima

Vale destacar que:

O segundo quartil (Q2) = Mediana

Exemplo:


```
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])
```

```
print(x.quantile([0.25, 0.50, 0.75]))
```


```
print(x.median())
```

Decil: São os valores que dividem um conjunto de dados em 10 partes iguais.



```
print(x.quantile([i / 10 for i in range(1, 10)]))
```

Centil: São os valores que dividem um conjunto de dados em 100 partes iguais.




```
print(x.quantile([i / 100 for i in range(1, 100)]))
```



Ao término da **Análise Exploratória de Dados (AED)**, ocorre a elaboração do **Relatório Estatístico**, também denominado Relatório de Inteligência.

Os Relatórios Estatísticos têm como objetivo **resumir, organizar e comunicar informações** sobre uma amostra ou população de maneira clara, objetiva e visualmente compreensível, auxiliando na interpretação dos dados e na tomada de decisões.

Retomando o Boxplot



Exemplo:

```
import matplotlib.pyplot as plt
import pandas as pd
```

```
x = pd.Series([2, 4, 3, 4, 5, 2, 4])
```

```
plt.boxplot(x, patch_artist=True,
            boxprops=dict(facecolor="red"))
plt.show()
```

```
print(x.describe())
```


Outliers: Dados extremamente discrepantes com relação ao conjunto, ultrapassando o Limite Inferior e/ou o Limite Superior:

$$LI = Q1 - 1,5.(Q3 - Q1)$$

$$LS = Q3 + 1,5.(Q3 - Q1)$$

Onde:

$(Q3 - Q1)$ = Amplitude Interquartílica
ou
Intervalo Interquartílico



Exercício 1:

O dataset “DadosAula.xlsx” apresenta os dados referentes a uma amostra de 234 funcionários de uma empresa de tecnologia. Supondo que você seja o Cientista de Dados da empresa, faça uma análise exploratória da variável “Salario” contendo:

- a) As Medidas de Tendência Central.
- b) As Medidas de Dispersão.
- c) As Medidas Separatrizes.
- d) Análise Gráfica.
- e) Interprete os resultados e dê pelo menos 3 insights.

Resposta:

Primeiramente devemos baixar e habilitar as bibliotecas:

pandas

openpyxl

matplotlib.pyplot

Na sequência, devemos importar o dataset:

import pandas as pd

Dados = pd.read_excel("DadosAula4.xlsx", engine="openpyxl")

print(Dados) (O dataset deve estar no Diretório do Python para funcionar)

a) `print(Dados["Salario"].mean())`

`print(Dados["Salario"].median())`

`print(Dados["Salario"].mode())`

```
b) print(Dados["Salario"].max(), Dados["Salario"].min())
```

```
print(Dados["Salario"].max() - Dados["Salario"].min())
```

```
print(Dados["Salario"].var())
```

```
print(Dados["Salario"].std())
```

```
print((Dados["Salario"].std() / Dados["Salario"].mean()) * 100)
```

c) `print(Dados["Salario"].quantile([0.25, 0.5, 0.75]))`

`print(Dados["Salario"].quantile([i/10 for i in range(1, 10)]))` (Optativo)

`print(Dados["Salario"].quantile([i/100 for i in range(1, 100)]))` (Optativo)

d) `import matplotlib.pyplot as plt`

```
plt.hist(Dados["Salario"], color="blue", bins=5)
plt.title("Salário dos Funcionários")
plt.xlabel("Salários")
plt.ylabel("Frequência")
plt.show()
```

ou

```
import matplotlib.pyplot as plt

plt.boxplot(Dados["Salario"], patch_artist=True,
            boxprops=dict(facecolor="blue"))
plt.title("Salário dos Funcionários")
plt.xlabel("Dados da Empresa")
plt.ylabel("Salários")
plt.show()
```

e) Resposta individual, utilizar os dados estatísticos encontrados.

Exercício 2:

O dataset “DadosAula.xlsx” apresenta os dados referentes a uma amostra de 234 funcionários de uma empresa de tecnologia. Supondo que você seja o Analista de Dados da empresa, faça uma análise exploratória da variável “VR” contendo:

- a) As Medidas de Tendência Central.
- b) As Medidas de Dispersão.
- c) As Medidas Separatrizes.
- d) Análise Gráfica.
- e) Interprete os resultados e dê pelo menos 3 insights.

Exercício 3:

O dataset “DadosAula.xlsx” apresenta os dados referentes a uma amostra de 234 funcionários de uma empresa de tecnologia. Supondo que você seja o Analista de BI da empresa, faça uma análise exploratória da variável “Cargo” contendo:

- a) A moda.
- b) Análise Gráfica.
- c) Interprete os resultados e dê pelo menos 3 insights.

Exercício 4:

O dataset “DadosAula.xlsx” apresenta os dados referentes a uma amostra de 234 funcionários de uma empresa de tecnologia. Supondo que você seja o Estatístico da empresa, faça uma análise exploratória da variável “Área” contendo:

- a) A moda.
- b) Análise Gráfica.
- c) Interprete os resultados e dê pelo menos 3 insights.

Material Complementar

Para aprofundar o tema, consulte os seguintes materiais:

https://www.ime.usp.br/~rvicente/Guedes_etal_Estatistica_Descriptiva.pdf (Acesso em 08/2025).

https://www.alura.com.br/artigos/estatistica-descritiva?srsId=AfmBOopSEVQfmmelnL75RM_pldHULZ5tQJxfrfy-0sx-3Q4C0OdjMrmP (Acesso em 08/2025).

<https://pt.khanacademy.org/math/statistics-probability/summarizing-quantitative-data/box-whisker-plots/a/identifying-outliers-iqr-rule> (Acesso em 08/2025).

OBRIGADO!

Contato:
profrodolfo.paiva@fiap.com.br

Copyright © **2023** Professor Me. Eng. Rodolfo Magliari de Paiva

Todos direitos reservados. Reprodução ou divulgação total ou parcial deste documento é expressamente proibido sem o consentimento formal, por escrito, do Professor (autor).